Bu çalışma nereden çıktı?

BRCA MODEL REHBERİ

Hasta dosyalarından modele: ne yaptık, nasıl hesaplıyoruz, neyi henüz bilmiyoruz?

Genetik, istatistik veya programlama bilmeyen; konuyu sıfırdan öğrenmek isteyen öğrenciler için hazırlanmıştır.

> **Bu rehber mevcut çalışmayı açıklar. Yeni hasta analizi, hipotez testi, yeniden eğitim veya hesaplayıcı değişikliği yapılmadı.**

Önce kayıtları anlamak, sonra doğru soruyu sormak

1. Kayıtları birleştirmek: Hangi dosya kime ait? Aynı kişi birkaç kez mi kaydedilmiş? Kimler aynı aileden?
2. Sonucu tahmin etmek: 1.295 hastadan öğrenen model, yeni girilen bilgilerle nasıl bir hesap yapıyor?
3. Biyolojik bir ilişki aramak: Genetik değişikliklerle tümör özellikleri arasında gördüğümüz fark gerçek olabilir mi, yoksa tesadüf ya da eksik kayıtlarla mı açıklanıyor?

Rehberde nasıl ilerleyelim?

Önce genetiğin temelini ve elimizdeki dosyaları tanıyacağız. Ardından bilgisayarın bu bilgilerden nasıl öğrendiğini ve bir hasta için hesabın nasıl yapıldığını göreceğiz. Sonunda sayıların ne kadar güvenilir olduğunu, laboratuvarda ne anlama geldiğini ve hâlâ hangi verilere ihtiyaç duyduğumuzu konuşacağız.

Rehber tarihi 3 Kasım 2026'dır. Arşiv ve doğrulama sayıları mevcut 24 Ekim denetiminden alınmıştır. Ayrı araştırma raporunun 25 Ekim tarihi değiştirilmemiştir. Modelin kayıtlı sürümü: 2026-10-04-8cc48aa58b.

Model ayrıntıları sayfasını aç

1 · Genetik bilmeden başlayalım

Vücudumuz hücrelerden oluşur. DNA (deoksiribonükleik asit), protein üretiminde kullanılan genetik bilgiyi taşır. Gen, bu bilginin belirli bir işlevle ilişkili bölümüdür. Proteinler hücrenin birçok işini yapan moleküllerdir.

BRCA1 ve BRCA2, DNA hasarını onarmaya yardımcı olan proteinlerle ilişkili genlerdir. Bir genetik değişikliğe varyant denir. Kalıtsal bir varyant aile içinde aktarılabilir. Tümörde sonradan oluşan somatik değişiklik ise bununla aynı şey değildir.

Terim	Anlamı
P / Pathogenic	Patojenik; hastalıkla ilişkili zarar verici etkisi gösterilmiş.
LP / Likely Pathogenic	Olası patojenik; zarar verici etkiye ilişkin güçlü kanıt.
VUS / Variant of Uncertain Significance	Anlamı belirsiz varyant; etkisi yeterince bilinmiyor.
B / LB	Benign / likely benign: zararsız / olası zararsız.
CNV / Copy Number Variant	Bir DNA bölümünün kopya sayısındaki değişiklik.
NGS / Next-Generation Sequencing	Çok sayıda DNA bölgesini paralel inceleyen dizileme yöntemleri.
MLPA / Multiplex Ligation-dependent Probe Amplification	Belirli bölgelerde kopya kaybı veya artışını değerlendiren yöntem.

> **Her varyant zararlı değildir. Hastalıkla ilişkili bir BRCA varyantını taşımak, kesinlikle kanser olunacağı anlamına gelmez.**

Tahmin sorumuz, kişinin gelecekte kanser olup olmayacağı değildir. Mevcut klinik bilgilerin kayıtlı BRCA test sonucunu tahmin etmeye yardımcı olup olamayacağını araştırıyoruz.

2 · Elimizde ne vardı, kayıtları nasıl bir araya getirdik?

Çalışmanın başında önümüzde hazır, tek bir hasta tablosu yoktu. Drive'da hasta klasörleri, genetik raporlar, genetik değişiklik listeleri ve 2019, 2020, 2022 gibi farklı yıllardan klinik dosyalar vardı. Aynı kişi birkaç dosyada, hatta farklı örnek numaralarıyla bulunabiliyordu. Bu yüzden ilk iş sayıları toplamak değil, kayıtların kime ait olduğunu anlamaktı.

Kayıt düzeyi	Sayı
Hasta klasörleri	2,259
Genetik kayıtlarda ayrı kişi olarak izlenen kimlikler	2,148
Klinik kaynak sürümlerindeki satırlar	7,939
Genetik ve klinik kayıtları güvenilir biçimde eşleştirilen kişiler	1,445
Kayıtlarda tutarlı biçimde izlenen aile numaraları	1,989
Kontrollerden sonra değerlendirmeye alınan genetik bulgu satırları	84,492

Bu sayılar aynı şeyi saymaz ve tek bir hasta seçim zinciri gibi birbirinden çıkarılamaz. 2.148, bütün arşivin kesin benzersiz hasta toplamı değildir; klinik kayıtları olup genetik bağlantısı henüz kabul edilmeyen bileşenler otomatik olarak ek kişi sayılamaz. Aile numarası farklı olması, belgelenmemiş akrabalığı dışlamaz.

84.492 satır, 84.492 benzersiz varyant değildir. Aynı varyant farklı kişilerde görülebilir. Bir varyantın tabloda olmaması da o DNA bölgesinin yeterli kalitede incelenip negatif bulunduğunu kanıtlamaz; tam incelenebilirlik maskeleri mevcut değildir.

İki dosyada benzer bir kod görmek yetmez. Hasta kodunu; isim, doğum tarihi, aile numarası, protokol numarası ve asıl raporla birlikte kontrol etmek gerekir. Bu ayrıntı önemlidir: yanlış eşleşme, bir kişinin tümör bilgisini başka birinin genetik sonucuyla karşılaştırmamıza yol açabilir.

Dosya sayısı ≠ satır sayısı ≠ örnek sayısı ≠ kişi sayısı ≠ bağımsız aile sayısı.

3 · Model hangi hastalardan öğrendi?

Hesaplayıcı, genişleyen arşivin tamamıyla değil, özgün 1.295 kişilik geliştirme grubuyla kurulmuştur. Tanı yılları 1988–2020 arasındadır. Meme ile ilişkili ilk dört kategori toplam 1.088 kişi; yalnız over grubu 207 kişidir.

Tanı	Kişi	Positive
Tek taraflı meme	978	104
Bilateral meme	75	17
Meme ve over	22	10
Erkek meme	13	2
Yalnız over	207	34
Toplam	1295	167

Hedef değişken y, kaydın BRCA_status_v3_strict etiketi tam olarak Positive ise 1, diğer etiketlerde 0'dır. Diğer 1.128 etiketin tamamını güncel, eksiksiz klinik negatiflik olarak kabul etmiyoruz.

$$\pi = \frac{167}{1295} \approx 0.12896 = 12.9\%$$

Burada π, geliştirme grubunun pozitif etiket oranıdır; genel toplumun taşıyıcılık oranı veya geometrik π sabiti değildir.

Alan	Açıklama
Tanı yaşı	Tanı konduğu zamanki yaş; bugünkü yaş değil.
Aile öyküsü	Akrabalık derecesi, kanser türü, tanı yaşı ve kişi sayımı.
Grade	Mikroskobik hücre farklılığı; evre ile aynı değildir.
Evre	Kanserin anatomik yayılımı; bu hesaplayıcıda kullanılmaz.
Köken bölgesi	Kayıtlı coğrafi kategori; doğrudan genetik soy ölçümü değil.

Birinci derece akrabalar anne, baba, kardeş ve çocukları; ikinci derece örneğin büyükanne, büyükbaba, teyze, hala, dayı ve amcayı kapsar. Her arşiv alanı model girdisi değildir: tümör boyutu ve lenf nodu durumu bu modelde kullanılmaz.

4 · Hasta bilgileri bilgisayarın anlayacağı sayılara nasıl çevrildi?

Terim	Tam açılım ve anlam
ER	Estrogen Receptor. Östrojen reseptörü.
PR	Progesterone Receptor. Progesteron reseptörü.
HER2	Human Epidermal Growth Factor Receptor 2. Tümör değerlendirmesinde kullanılan reseptör/protein.
TNBC	Triple-Negative Breast Cancer. ER, PR ve HER2 negatif meme kanseri.
Ki-67	Hücre çoğalmasıyla ilişkili belirteç; genellikle yüzde olarak kaydedilir.
IHC	Immunohistochemistry. Dokuda proteinleri boyamayla değerlendirme.
ISH / FISH	In Situ Hybridization / Fluorescence In Situ Hybridization. Dokuda belirli DNA/RNA hedeflerini değerlendiren yöntemler.

Kodlama: yaş 38 gibi sayısal; akraba sayısı 1 gibi sayım; TNBC varsa 1, yoksa 0 şeklinde gösterge olur. Tanı, grade ve bölge kategorilere ayrılır. Tek taraflı meme, g2 ve Marmara referanstır; bunlar için ek kategori katsayısı yoktur.

Geliştirme paketinde 87 yaş eksik, 16 bölge kayıt dışıdır. Ki-67, 464 kişide kayıtlıdır. Eksik veriyi hesapta kullanılabilir hale getirmeye atama (imputation) denir.

Tarihsel işlem: eksik aile sayımları 0; eksik yaş tanı grubu medyanı ve eksiklik göstergesi; eksik bölge Marmara; eksik Ki-67 değeri 30 ve ayrı eksiklik göstergesi 1. Grade 1 veya 3 dışındakiler g2 referansına gider. Canlı panel boş yaşla kişisel sonuç üretmez. Yalnız over seçimi TNBC'yi kapatır ve Ki-67'yi eksik yapar.

Bilinmeyen bilgi, bilinen sıfır değildir. Ki-67 bilinmiyor ile ölçülmüş %30 aynı şey değildir. Bu işlemler geçmiş modelin kurallarıdır; yeni klinik gerçekler değildir.

5 · Bilgisayar neye ne kadar önem vereceğini nasıl öğrendi?

Bilgisayara yalnız hasta bilgilerini değil, kayıtlardaki test sonuçlarını da verdik. Bilgisayar bir tahmin yaptı, bunu bildiğimiz sonuçla karşılaştırdı ve hatayı azaltmak için bilgilere verdiği ağırlıkları değiştirdi. Bu ağırlıklara katsayı, onları bulma işine eğitim denir. Kullandığımız yöntem lojistik regresyondur. Yani karmaşık bir sinir ağı değil, katkıları toplayan ve toplamı olasılığa çeviren bir modeldir.

Pozitifler azınlık olduğundan sınıf ağırlıkları kullanılmıştır. Bir pozitif kayıttaki hata, eğitimde bir diğer etiketli kayıttaki hatadan daha fazla ağırlık alır; yeni hasta yaratılmaz.

$$w_+ = \frac{1295}{2 \times 167} \approx 3.877246, \qquad w_- = \frac{1295}{2 \times 1128} \approx 0.574025$$

Bir model geçmiş hastaları çok iyi ayırıp yeni hastalarda başarısız olabilir. Buna aşırı uyum, yani overfitting denir. Bunu sınırlamak için çok büyüyen katsayılara ek bir bedel koyulur: L2 cezası. Bu çalışmadaki C ayarı küçüldükçe ceza güçlenir. Amaç geçmiş kayıtları ezberlemektense yeni hastalarda da işe yarayabilecek bir ilişki öğrenmektir.

C adayları: 0,01; 0,03; 0,1; 0,3; 1. Ana betik 5 dış kat × 5 tekrar kullanır. Her dış eğitim grubunda 3 iç kat ile AUC üzerinden C seçilir. En sık seçilen değer 0,3'tür; son model bütün geliştirme verisine kurulur. max_iter = 5000 bir üst yineleme sınırı; seed = 2020 tekrarlanabilirlik ayarıdır, kalite garantisi değildir.

Standartlaştırma, yaş ve Ki-67 gibi farklı ölçeklerdeki girdileri eğitim için ortak ölçeğe taşır. Katsayılar daha sonra ham birimlere dönüştürülmüştür. Canlı panelde tekrar standartlaştırma yapılmaz.

Ana yolda kişi başına tekrarlı kat dışı ham olasılıklar ortalanmış, logit değerleriyle Platt kalibrasyonu öğrenilmiştir. Ayrı kuyruk değerlendirme betiği ise dış eğitimde ölçekleme, iç kat dışı tahminlerle kalibrasyon ve dış testte sayım yapar. Bu yollar tek bir özdeş değerlendirme zinciri değildir.

6 · Hesabın ağırlıkları: katsayılar ne anlatıyor?

Her hasta bilgisi, öğrenilmiş bir ağırlıkla çarpılır. Örneğin yaşın katkısı, yaş ile yaş katsayısının çarpımıdır. Bütün katkılar toplanınca z dediğimiz ara sayı oluşur. Katsayı pozitifse bu toplam artar, negatifse azalır. Bu sayılar doğrudan yüzde değildir; bir özelliğin hastalığa neden olduğunu da göstermez. Tabloda okumayı kolaylaştırmak için yuvarlanırlar, hesapta tam değerleri kullanılır.

Girdi	Katsayı
Sabit başlangıç	-1.608284
Tanı yaşı	-0.029742
1. derece meme <40	1.617774
1. derece meme ≥40	0.675359
2. derece meme <40	0.612541
2. derece meme ≥40	0.566324
3.–4. derece meme	0.386057
1. derece over	0.865623
2.–4. derece over	0.741728
1. derece diğer kanser	0.212743
Yaş eksik göstergesi	1.067055
TNBC	0.809504
Ki-67, yüzde birimi başına	0.025036
Ki-67 eksik göstergesi	0.377173
Bilateral meme	0.817837
Meme ve over	1.184748
Erkek meme	0.498472
Yalnız over	0.317136
Grade 1	0.089786
Grade 3	0.643779
Karadeniz	-0.092277
Doğu Anadolu	-0.215376
İç Anadolu	0.160451
Balkanlar	0.405355
Güneydoğu Anadolu	-0.384251
Ege	0.347375
Akdeniz	-0.631471

Referanslar: tek taraflı meme, g2 ve Marmara. Bir hastada bütün göstergeler etkin değildir. Etnik köken gibi araştırmada kullanılan bazı düzeltme değişkenleri bu tahmin modelinde yer almaz.

7 · Bir örnek üzerinden birlikte hesaplayalım

Bu bir kurgu eğitim profilidir; kimliği belirlenebilir gerçek hasta değildir.

Özellik	Değer
Tanı yaşı	38
Tanı / grade / bölge	Tek taraflı meme / 2 / Marmara
TNBC	1
1. derece meme <40	1
Diğer aile sayımları	0
Ki-67	Bilinmiyor
Aciliyet kutuları	Seçili değil

$$z = \beta_0 + \sum_{j=1}^{26} \beta_j x_j$$

x_j: hastanın j numaralı girdisi. β_j: o girdinin katsayısı. β_0: sabit başlangıç. j: girdi sırası. Σ: bütün katkıları topla. z: doğrusal skor, yüzde değil.

$$\begin{aligned} z = & -1.608283515050 \\ & + 38(-0.029741519309) \\ & + 1(1.617774083556) \\ & + 1(0.809503755804) \\ & + 30(0.025035821777) \\ & + 1(0.377172660529) \end{aligned}$$

$$\begin{aligned} z = & -1.608283515050 - 1.130177733759 \\ & + 1.617774083556 + 0.809503755804 \\ & + 0.751074653320 + 0.377172660529 \\ = & \, 0.817063904400 \end{aligned}$$

Ki-67 bilinmediği için hem 30 ataması hem eksiklik göstergesi katkı yapar. Ölçülmüş %30 olsaydı eksiklik katkısı olmazdı. Diğer kategori ve aile göstergeleri bu örnekte sıfır katkı yapar.

8 · Topladığımız sayı nasıl yüzdeye dönüşüyor?

Sigmoid, herhangi bir doğrusal skoru 0–1 aralığına dönüştürür. e ≈ 2,71828 Euler sayısıdır; üstteki ifade üs anlamına gelir. p bir olasılık, raw ham, cal kalibre edilmiş demektir.

$$\sigma(t) = \frac{1}{1 + e^{-t}}$$

$$p_{\text{raw}} = \frac{1}{1 + e^{-0.817063904400}} \approx 0.693612733313$$

Yaklaşık %69,4, ekrandaki son yüzde değildir. Kalibrasyon, yüzdelerin gözlenen oranlarla uyumunu ele alır. Sınıf ağırlıklı modelin ham yüzdesi, doğrudan son yüzde olarak kullanılmaz.

$$\eta = a + bz, \quad a = -1.824095746896, \quad b = 0.939227549588$$

$$\begin{aligned} \eta &= -1.824095746896 + 0.939227549588(0.817063904400) \\ &= -1.824095746896 + 0.767408928786 \\ &= -1.056686818109 \end{aligned}$$

$$p_{\text{cal}} = \frac{1}{1 + e^{-\eta}} = \frac{1}{1 + e^{1.056686818109}} = 0.257943116995$$

$$100p_{\text{cal}} = 25.7943116995\% \approx \boxed{25.8\%}$$

η (eta), düzeltilmiş doğrusal skordur; a sabit, b eğim düzeltmesidir. Kalibrasyon yalnız bir kez uygulanır. a+bz içine z yerine ham olasılığı koymak yanlış olur. Logit, sigmoidin ters dönüşümüdür: log[p/(1−p)]. Odds = p/(1−p); OR (Odds Ratio) iki odds değerinin oranıdır, yüzde puan değildir. Son kalibre edilmiş log-odds için katsayı bβ'dır.

Yalnız yaşı 38'den 48'e değiştirirsek

$$\Delta z = 10(-0.029741519309) = -0.297415193094$$

$$z_{\text{new}} = 0.519648711306, \qquad p_{\text{new}} \approx 0.208164117 = 20.8\%$$

Düşüş yaklaşık 4,98 yüzde puandır. Bu, on yıl yaşlanmanın koruyucu etkisi değildir; sabit modelin farklı bir girdiye verdiği koşullu hesaptır. Önceki değerleri gösteren oklar, son düzenlemeden etkilenen sayıları izlemeye yarar.

9 · Puan kartı ile model aynı şey mi?

Kart ayrı bir sınıf dengeli, L2 cezalı modelden gelir: 16 aday özellik, C = 0,3. Katsayılar 0,5 log-odds birimine bölünüp yuvarlanmış; sıfır puanlı satırlar çıkarılınca 14 satır kalmıştır. Ana modelin β katsayılarını doğrudan yuvarlamak değildir.

Ölçüt	Puan
Tanı yaşı < 40	1
Üçlü negatif tümör	2
Grade 3	1
Ki-67 ≥ %30	1
1. derece akrabada meme kanseri < 40 yaş (kişi başına, en çok 2)	3
1. derece akrabada meme kanseri ≥ 40 yaş (kişi başına, en çok 2)	1
2. derece akrabada meme kanseri (kişi başına, en çok 2)	1
3.–4. derece akrabada meme kanseri (kişi başına, en çok 2)	1
1. derece akrabada over kanseri (kişi başına, en çok 2)	1
2.–4. derece akrabada over kanseri (kişi başına, en çok 2)	1
Bilateral meme kanseri	2
Hem meme hem over kanseri	2
Over kanseri	2
Erkek meme kanseri	1

Örnekte: yaş <40 için 1, TNBC için 2, birinci derece meme <40 için 3; toplam 6. Ki-67 bilinmiyor olduğundan yüksek Ki-67 kart puanı yoktur. Aile sayımı kart satırında en çok 2, modelde panel sınırı 6’dır.

Şerit	Model	Kart
Normal	<10%	0–3
Öncelikli	10%–<20%	4
Acil	≥20%	≥5

$$A = \max(s_{\text{card}}, s_{\text{model}}, u), \qquad B = \max(s_{\text{model}}, u)$$

s değerleri 0 normal, 1 öncelikli, 2 acil kodlarıdır; max en büyüğü seçer. Tedavi kararı bekliyorsa u=2; aksi halde ailede belgeli P/LP kutusu seçiliyse u=1; değilse 0. B öneridir. A’da acil şerit, B’de model ≥%20 hızlı paketi tetikler. Aile P/LP kutusu β toplamını değiştirmez; ancak bilgi modelde olmadığı için kişisel yüzde başlığı bastırılır.

10 · Ekrandaki diğer sayılar ne demek?

Aynı hastanın farklı sayılarını karıştırmayın

$$N = \text{round}(1/p) = \text{round}(3.876824) = 4$$

“Yaklaşık dört kişiden biri” yuvarlanmış anlatımdır; dört gözlenmiş kişi değildir. Round en yakın tamsayıya yuvarlar; kodda tam yarımlar çift tamsayıya gider.

$$\text{Position} = \text{round}\left[5\left(17 + \frac{0.257943117 - 0.2133526175}{0.2763791363 - 0.2133526175}\right)\right] = 89$$

Skor sırası yaklaşık 89. yüzdeliktir: geliştirme skor dağılımındaki konum, %89 taşıyıcılık olasılığı değil. 17 alt düğümün sıfırdan başlayan sırası; kesrin paydası iki komşu düğüm arasındaki farktır.

$$\text{Fill} = \min\left(100, \frac{p}{0.40} \times 100\right) \approx 64.5\%$$

Fill görsel çubuk doluluğudur; min küçük olanı seçer. Bu %64,5 ikinci bir tıbbi olasılık değildir.

Kayıtlı performans değerleri

Ölçüt	Değer
İç içe çapraz doğrulama AUC	0.776
AUC güven aralığı	0.733–0.817
Görünür / iyimserlik düzeltilmiş AUC	0.815 / 0.784
PR-AUC	0.404
Zamansal test AUC	0.788
Yeniden kalibre edilmiş Brier	0.095
Temel oran Brier	0.112

AUC: Area Under the Receiver Operating Characteristic Curve. Pozitif bir kaydı diğer etiketli bir kaydın üstünde sıralama yeteneğidir; 0,776 “kişilerin %77,6’sını doğru bildi” demek değildir. ROC, duyarlılığı yanlış pozitif oranına karşı çizer. PR-AUC: Precision–Recall eğrisi altındaki alan; pozitif sınıfı bulma performansını ele alır.

11 · Model ne kadar iyi? Bunu nasıl anlarız?

$$\text{Brier} = \frac{1}{n}\sum_{i=1}^{n}(p_i - y_i)^2$$

n değerlendirilen kişi sayısı; p_i kişinin tahmini, y_i kayıtlı sonucu. Brier, olasılık hatasını ölçer; düşük daha iyidir. Kalibrasyon, örneğin %20 denilen gruplarda gözlenen oranın buna yakın olup olmadığıdır. İyi sıralama, iyi kalibrasyonu garanti etmez.

Kat dışı tahmin, kişi o adımda eğitim dışında tutulurken üretilir. Ancak ana betikte bazı atama ve ölçekleme dış kat ayrımından önce yapılmıştır: veri sızıntısı riski vardır. StratifiedKFold sınıf oranlarını gözetir ama aileleri gruplamaz. Akrabalar farklı katlara düşebilir. AUC aralığı 2.000 kişi bazlı bootstrap; iyimserlik düzeltmesi 200 bootstrap kullanır. Bootstrap, örnekten tekrar yerine koyarak örnekleme işlemidir.

Zamansal tabloda 796 eğitim ve 477 test kişisi vardır; test dönemindeki pozitif sayısı 52'dir. Aynı merkezin daha sonraki dönemi, bağımsız dış doğrulama değildir. Farklı değerlendirme tablolarının paydaları ve işlem yolları birbirinin yerine kullanılamaz.

Tarihsel yaklaşık %3,5 eşik örneği

	Positive	Diğer	Toplam
Eşik üstü	TP 159	FP 978	1,137
Eşik altı	FN 8	TN 150	158
Toplam	167	1,128	1,295

$$\text{Sensitivity} = \frac{TP}{TP+FN} = \frac{159}{167} = 95.21\%$$

$$\text{Specificity} = \frac{TN}{TN+FP} = \frac{150}{1128} = 13.30\%$$

$$\text{NPV} = \frac{TN}{TN+FN} = \frac{150}{158} = 94.94\%, \quad \text{PPV} = \frac{159}{1137} = 13.98\%$$

TP/FP: True/False Positive; TN/FN: True/False Negative, kayıt etiketlerine göre doğru/yanlış eşik sınıflaması. Duyarlılık pozitifleri yakalama; özgüllük diğerlerini aşağıda tutma; NPV (Negative Predictive Value) eşik altındakilerin diğer etiket oranı; PPV (Positive Predictive Value) eşik üstündekilerin pozitif oranıdır. Yüksek duyarlılık tek başına yeterli değildir. Bu örnek güncel %10/%20 sıra sınırları değildir; tek eşik tablosu AUC vermez.

12 · Daha az hızlı test yaparsak ne kazanır, ne kaybederiz?

İki karar ayrıdır: kim sırada öne alınır, kime dar kapsamlı hızlı ilk test paketi uygulanır? Hızlı paket BRCA1 MLPA delesyon/duplikasyon incelemesi ve c.5266dupC hedefini kapsar. Bütün BRCA varyantlarını inceleyen tam test değildir. Hızlı test negatifliği taşıyıcılığı dışlamaz; tam test devam eder.

Strateji	Paket	Saptanabilir hedef
Model ≥%20	212.6	26.6
Kart veya model A tetikleyicisi	280.0	29.4

Bunlar beş tekrarın ortalamalarıdır; ondalık sayılar parçalı hastalar değildir. Saptanabilir hedef, bu dar paketin kapsadığı hedefi taşıyan seçilmiş kişidir; bütün BRCA pozitifleriyle aynı payda değildir.

$$\Delta N = 212.6 - 280 = -67.4, \qquad \Delta T = 26.6 - 29.4 = -2.8$$

$$\text{Yield} = \frac{26.6}{212.6} \times 100 = 12.511759\%$$

$$\text{Packages/target} = \frac{212.6}{26.6} = 7.992481$$

Δ, iki seçenek arasındaki farkı gösterir. N hızlı test paketi sayısı, T bu paketin saptayabildiği hedefleri taşıyan kişi sayısıdır. Daha az paket kullanınca iş yükü azalır; buna karşılık daha az hedef bulunabilir. İkisini birlikte görmek gerekir. Tekrarlardaki oranların ortalaması 8,013; ortalama sayıları birbirine bölünce sonuç yaklaşık 7,992'dir. Bunlar farklı hesaplar olduğu için eşit olmaları beklenmez.

Kapasite paneli altı kayıtlı stratejinin toplu sonuçlarını okur; yeni hasta analizi yapmaz. Zamansal seçenek 477 kişi ve 52 taşıyıcıya aittir. Aciliyet kutularının ek iş yükü ölçülmemiştir. Aynı sayıda hasta seçilen karşılaştırmada kart ek üstünlük göstermemiş; elle kullanım ve açıklama değeri ayrıdır.

> **Bekleme süresi, maliyet veya tedavi sonucundaki iyileşme ölçülmedi. Varsayımsal test azaltma paneli bir test atlama talimatı değildir.**

Varsayımsal azaltma politikası düşük olasılığa ek olarak kart ≥4, over, erkek meme, TNBC, ailede over, aciliyet ve sıkı seçenekte <45 yaşı dışlar. Kayıtlı üretim betiği bu pakette olmadığından toplu azaltma sonuçları burada bağımsız yeniden üretilmiş sayılmaz.

13 · 87 ailede gördüğümüz farkı neden kesin sonuç saymıyoruz?

Tahmin, hangi bilgi birleşiminin sonucu öngördüğünü sorar. Biyolojik ilişki araştırması ise örneğin iki varyant grubunun tümör boyutlarının farklı olup olmadığını sorar. İyi tahmin, neden-sonuç ilişkisi kanıtı değildir.

Mevcut karşılaştırma 87 aile temsilcisidir: stop-gain grubunda 20, frameshift grubunda 67 aile. Stop-gain protein üretimine erken dur işareti getirir; frameshift DNA'nın üçlü okunma düzenini kaydırır. Yaş, yıl, gen, kayıtlı etnik köken, bölge ve genotip kaynağına göre düzeltilmiş kaydedilmiş boyut oranı aşağıdadır.

$$R = 0.649, \qquad \text{interval: } 0.421 \text{ to } 1.001$$

Nokta tahmini yaklaşık %35 daha küçük kaydedilmiş boyuta karşılık gelir. Aralık fark olmamasını belirten 1'i içerir. Birincil ampirik p yaklaşık 0,0504; birikimli çoklu test düzeltmesi q yaklaşık 0,527'dir. Bu doğrulanmış bir fark değildir ve hesaplayıcıya eklenmemiştir.

Terim	Anlam
Etki büyüklüğü	İlişkinin büyüklüğü; burada boyut oranı.
Güven aralığı	Örnekleme belirsizliğini anlatır; bu tek aralığa ilişkin doğruluk olasılığı değildir.
p-value	Sıfır hipotezi ve model varsayımları altında en az bu kadar uç sonuç olasılığı; hipotezin yanlış olma olasılığı değil.
Karıştırıcı	Hem grup hem sonuçla ilişkili olup karşılaştırmayı bozabilen değişken.
Seçilim yanlılığı	Dahil edilen ve dışlanan kişilerin sistematik farklılığı.
Güç	Belirli bir gerçek etkiyi belirli tasarımla saptayabilme olasılığı.
FDR / False Discovery Rate	Çoklu karşılaştırmalarda yanlış keşif oranını kontrol eden yaklaşım.

Yeterince çok karşılaştırma yaparsak, yalnız şans eseri dikkat çekici farklar görebiliriz. Çoklu test düzeltmesi bunun için yapılır; eksik kayıtları veya bazı hastaların grupta daha fazla temsil edilmesini ise tek başına çözmez. Bu gözlemde o sorunlar sürüyor. Aynı farkın ayrı hastalarda da görülüp görülmediği henüz sınanmış değil.

14 · Daha çok dosyamız var; neden hâlâ ayrı hastalara ihtiyacımız var?

Arşivin büyümesi, modelin yeniden eğitildiği veya bağımsız doğrulandığı anlamına gelmez. Bir kişi eğitimde kullanıldıysa ya da aynı aileden geliyorsa bağımsız test için uygun olmayabilir. Kayıtlı aile ayrılığı, genomik akrabasızlık kanıtı değildir.

Mevcut denetim aşaması	Sayı
Geliştirme dışında klinik bağlantılı kişiler	206
Bilinen geliştirme aile örtüşmesiyle dışlanan	20
Uygun kanser kaydı olmayan	1
Kalan aday kişiler / aile grupları	185 / 184
Temel girdileri tam aile temsilcileri	111
Rapor destekli, temel girdileri tam	91
Tarihsel VUS bağımlılığı olmadan kalan	51
51 adayda pozitif / negatif	14 / 37
Tanı yılı var / eksik	41 / 10
Tam tarihli sonuç-öncesi profil / uygun doğrulama	0 / 0

91 rapor destekli temsilciden 40'ı tarihsel varyant sınıflandırmasına bağımlı olduğu için daha temkinli 51 kişilik incelemenin dışında tutuldu. Eksik tanı yılı bir model girdisi değildir; zaman sıralamasını doğrulamayı zorlaştırır. Yılı bulunan 41 kişide de bütün klinik girdilerin BRCA sonucundan önce kayıtlı olduğu gösterilemedi.

> **Genetik raporlar Drive'da var. Eksik olan, tüm girdileri doğru tahmin zamanında belgeleyen tarihli klinik kayıtlar. Sıfır uygun hasta, sıfır performans demek değildir; performans hesaplanamadı.**

Gerekenler: sonuç öncesi tarihli klinik değerlendirme ve model girdileri; izlenebilir genetik sonuç ve rapor tarihi; güvenilir kişi/aile bağlantıları; hem pozitif hem negatif sonuçlardan yeterli sayıda bağımsız kişi. Yeni katsayı, kalibrasyon veya eşik değişikliği sadece arşiv büyüklüğüyle gerekçelendirilemez.

15 · Bütün bunları bir araya getirelim

Hesaplayıcıda yaşı değiştirdiğinizde bilgisayar yeni bir şey öğrenmez. Daha önce öğrenilmiş katsayılarla hesabı tekrar yapar: bilgilerin katkılarını toplar, toplamı yüzdeye çevirir, ayrıca puan kartını ve sıra kurallarını uygular. Eğitim sayfasındaki kurgu örnekler bu hesabı görmeniz içindir; gerçek hasta bilgileri değildir.

54 kurgu örnek ve 47 kayıtlı öz-test, hesap eşleşmesini kontrol eder. Otomatik testler ile canlı masaüstü/mobil kontroller, yazılımın amaçlanan hesabı yaptığını gösterebilir. Dil geçişi girdileri korumalı; sıfırlama seçili profilin başlangıcına dönmelidir. Bunlar yeni hastalarda klinik başarı kanıtı değildir.

SHA-256 sağlama toplamı hangi dosya sürümünün kullanıldığını doğrular; verinin doğruluğunu veya bilimsel geçerliliği kanıtlamaz. Özgün genetik raporlar ve özel kimlik/aile bağlantı listeleri yetkili ekibin Drive kayıtlarındadır; bu rehber hasta kimliği içermez.

Bütün çalışmayı bir paragrafta anlatmak

Dağınık genetik ve klinik kayıtları eşleştirerek dosya, örnek, kişi ve aileyi ayırdık. Özgün 1.295 kişide kurulan lojistik modelin hesabını açıklıyoruz: ağırlıklı toplam, kalibrasyon ve yüzde. Puan kartı ile sıra kuralları ayrı katmanlardır. İç değerlendirme yararlı sıralama gösterse de veri işleme ve aile bağımsızlığı sınırlılıkları vardır. Biyolojik analizlerdeki 87 ailelik gözlem doğrulanmış keşif değildir. Geniş arşiv henüz tarihli, bağımsız bir doğrulama grubu sağlamadı. Elimizde hesabı açıklanabilen araştırma prototipi ve açık veri ihtiyaçları var; yeni hastalarda güvenilirlik için bağımsız doğrulama gerekiyor.

İzlenebilir mevcut kaynaklar

- Sabit katsayılar, hasta sayıları ve kayıtlı performans
- Hesap, kart ve A/B kuralları
- Mevcut yöntem denetimi ve semboller
- Arşiv sayımı
- 87 ailelik sonuç
- Doğrulama aday seçimi
- 51 adayda tarih denetimi
- Hızlı test kapasitesi

Bağlantılar kullanılan toplu kayıtlara gider; bunlar hasta düzeyindeki özgün belge denetiminin yerine geçmez. Rehber yeni bir klinik sınıflandırma veya test önerisi sunmaz.

16 · Yapay zekâ diyoruz; bizim modelimiz bunun neresinde?

Yapay zekâ (AI, Artificial Intelligence), bilgisayarlara öğrenme ve problem çözme gibi görevler yaptıran geniş alandır. Makine öğrenmesi (ML, Machine Learning), kuralları yalnız elle yazmak yerine veriden örüntü öğrenen yöntemleri kapsar. Derin öğrenme (DL, Deep Learning) ise çok katmanlı yapay sinir ağlarını kullanan makine öğrenmesi yöntemleridir.

> **Yapay zekâ → makine öğrenmesi → denetimli öğrenme → bizim lojistik regresyon modelimiz. Derin öğrenme, makine öğrenmesinin başka bir yöntem grubudur; hesaplayıcımız derin sinir ağı kullanmaz.**

Denetimli öğrenmede eğitim örneklerinin kayıtlı sonuç etiketleri vardır. Bizim çalışmamızda girdiler tanı yaşı, aile öyküsü ve belirli tümör özellikleri; öğrenilmek istenen etiket ise kayıtlı BRCA sonucudur. Eğitimde sonucu biliriz. Yeni bir kişiye tahmin yaparken ise sonuç-öncesi bilgileri kullanmak gerekir. Sonucu öğrendikten sonra kaydedilen bilgileri sanki önceden biliniyormuş gibi kullanmak, gerçek kullanımın güvenilir bir denemesi olmaz.

Aynı alanda farklı sorular

Soru	Girdi → çıktı	Bizim hesaplayıcı mı?
BRCA sonucu olasılığı	Klinik bilgiler → kayıtlı pozitif sonuç olasılığı	Evet; araştırma modeli
Varyant çağırma	Dizileme okumaları → DNA değişikliği çağrısı	Hayır; ör. DeepVariant ayrı görevdir
Varyantın anlamı	Bir değişiklik ve kanıtları → klinik sınıflama	Hayır; VUS bu modelle yeniden sınıflanmaz
Gelecekte kanser / tedavi yanıtı	Uygun başlangıç bilgileri ve takip → gelecekteki sonuç	Hayır; farklı hedef ve doğrulama gerekir

Karmaşıklık, doğruluğun garantisi değildir. Lojistik regresyon her girdiye bir katsayı verir; karar ağacı sorularla dallanır; K-en yakın komşu (KNN, K-Nearest Neighbours) benzer eğitim örneklerine bakar; destek vektör makinesi (SVM, Support Vector Machine) sınıfları ayıran bir sınır öğrenir; sinir ağları katmanlar boyunca dönüşümler öğrenir. Bu açıklamalar bir algoritma yarışmasının sonucu değildir. Bizim verimizde hangisinin daha iyi olduğunu söylemek, aynı hastalar ve aileleri ayıran aynı değerlendirme düzeniyle adil bir karşılaştırma gerektirir; burada böyle bir yeni karşılaştırma yapılmadı.

DeepVariant: özgün varyant çağırma çalışması

17 · Bilgisayar hatalarından nasıl öğreniyor?

Aşağıdaki sayılar yalnız kurgu bir ders örneğidir. Gerçek hasta, gerçek eğitim adımı veya yeni performans sonucu değildir. Hesaplayıcının kayıtlı katsayıları değiştirilmedi.

Öğrenme döngüsü: katsayılarla tahmin üret → kayıtlı etiketle karşılaştır → kaybı hesapla → katsayıları birlikte güncelle → tekrar et. En sonda yalnız eğitim hatası değil, eğitim dışında tutulan örneklerdeki sonuç da önemlidir. 5. bölüm, geçmiş çalışmada bu işin hangi ayarlar ve sınırlılıklarla yapıldığını anlatır.

Kayıp (loss), bir tahminin kayıtlı etiketten ne kadar uzak olduğunu ölçen eğitim ölçütüdür. Logaritmik kayıp (log loss), yanlış bir sonuca aşırı güvenmeyi ağır cezalandırır. Aşağıda y kayıtlı etikettir: pozitif için 1, diğer etiket için 0. p, eğitim sırasında üretilen ham pozitif olasılığıdır; ekrandaki son kalibre yüzde değildir. ℓ (küçük L), bir örneğin kaybı; ln doğal logaritmadır.

$$\ell = -\left[y \ln(p) + (1-y) \ln(1-p)\right]$$

Tek bir pozitif etiketli kurgu örnek

Kayıtlı etiketi pozitif olan bir örneğe %20 ham olasılık verilirse kayıp yaklaşık 1,609 olur. Aynı örneğe %80 verilirse yaklaşık 0,223 olur. Pozitif örneğe yalnız %1 vermek ise yaklaşık 4,605 kayıp üretir: bu, güvenle yapılmış yanlış tahminin daha ağır cezasıdır.

$$-\ln(0.20) \approx 1.609$$

$$-\ln(0.80) \approx 0.223$$

$$-\ln(0.01) \approx 4.605$$

Eğitim, tek bir örneğin yüzdesini artırma işi değildir: başka örneklerdeki hatalar da hesaba katılır. Sınıf ağırlıkları, az sayıdaki pozitif kayıtlardaki hatalara daha fazla ağırlık verir. L2 cezası, aşırı büyük katsayılara karşı denge kurar. Kaybın azalması eğitim verisine daha iyi uyum anlamına gelebilir; yeni hastalarda daha iyi sonuç alınacağını tek başına göstermez.

Bir katsayı β olsun. Kare cezasında β=1 için katkı 1, β=3 için katkı 9'dur; toplam cezanın büyüklüğü ayrıca ceza ayarına bağlıdır. Bu yalnız cezanın biçimini anlatır. Bizim kayıtlı ayarımızda C küçüldükçe düzenlileştirme güçlenir. C, elle hastaya göre ayarlanan bir risk düğmesi değildir.

$$1^2 = 1, \qquad 3^2 = 9$$

Eğitim ile kullanım farklı işlerdir

Eğitimde etiketlerden katsayılar öğrenilir; daha sonra kalibrasyon ve karar kuralları değerlendirilir. Canlı kullanımda kayıtlı katsayılar sabittir: girdiyi değiştirdiğinizde yalnız mevcut formüller yeniden hesaplanır. Girdileriniz yeni eğitim örneği olarak kaydedilmez. Bir öğrencinin kurgu profilindeki yüzdeyi değiştirmesi, modelin başarısını veya biyolojik bir etkiyi ölçmez.

Web sayfasındaki sekiz kurgu örnekle öğrenmeyi adım adım izleyebilirsiniz. Geri dönüp katsayıları, hataları ve yeni tahminleri karşılaştırın. Bu küçük ders deneyi gerçek modelin eğitim kaydı değildir.

Kurgu verilerle öğrenmeyi izleyin

Log loss: yöntem açıklaması

Lojistik regresyon ve düzenlileştirme: yöntem belgesi

18 · Önceki makale ile bu hesaplayıcı aynı çalışma mı?

Adibi ve Yazıcı'nın 2023 tarihli "Artificial Intelligence and Machine Learning Applications in Precision Medicine and Genomic Diagnostics" başlıklı kitap bölümü, alandaki uygulamaları tanıtan bir derlemedir. Bugünkü hesaplayıcının bağımsız doğrulama raporu değildir. Bölümün 72. sayfasındaki BRCA örneği, Yazıcı ve arkadaşlarının 2020 çalışmasına atıf yapar. Algoritma ve performans ayrıntıları için aşağıdaki özgün makaleyi esas alıyoruz.

Özellik	2020 yayını	Bugünkü hesaplayıcı
Veri grubu	2.070 yüksek riskli meme kanseri hastası; başlangıçta 125 özellik	Özgün geliştirme grubu: 1.295 kişi
Hedef	BRCA1/2 negatifliğini belirleme	Kayıtlı pozitif sonuç olasılığı ve ayrı test sırası kuralları
Yöntem	KNN, karar ağacı ve SVM karşılaştırmaları; dokuz özellikli veri grubu öne çıkarılır	Sınıf dengeli L2 lojistik regresyon + kayıtlı kalibrasyon; ayrı puan kartı
Bildirilen ölçüt	%92,88 doğruluk (accuracy)	Kayıtlı iç çapraz doğrulama AUC: 0,776; yöntem sınırlılıkları 11. bölümde
Bağımsız doğrulama	Bu yayının bulunması bugünkü modeli doğrulamaz	Geniş arşivden henüz uygun, tarihli bağımsız grup sağlanmadı

> **2.070, 1.295 ve arşivdeki 2.148 farklı kayıt kapsamlarını anlatır. Bu sayılar toplanamaz veya birbirinden çıkarılarak yeni/bağımsız hasta sayısı bulunamaz. Yayın ile bugünkü veriler arasındaki kişi ve aile örtüşmesi, yalnız bu sayılardan anlaşılamaz.**

Doğruluk, belirli bir karar eşiğinde doğru sınıflananların oranıdır. AUC ise eşikler boyunca sıralamayı özetler. %92,88 doğruluk ile 0,776 AUC aynı ölçekte iki başarı oranı değildir; doğrudan büyük-küçük karşılaştırması yapılamaz. Veri grubu, hedef etiket, sınıf dağılımı, hasta/aile ayrımı ve değerlendirme düzeni de eşleşmelidir.

Aynı araştırma alanı, yazarlar veya arşiv, aynı eğitilmiş model demek değildir. İki dakikadan kısa hesaplama süresi; bir genetik testin yerini alma, güvenli test azaltma, maliyet tasarrufu veya tedavi yararının ölçüldüğü anlamına gelmez. Bizim sitemiz bu sonuçları kanıtlanmış bir klinik yarar olarak sunmaz.

2020 özgün makale: PubMed kaydı ve tam metin bağlantısı

2020 özgün makale: DOI

2023 derleme bölümü: İstanbul Üniversitesi yayınevi kaynağı

Bu ek bölümler eğitim içindir. Gerçek hasta verileriyle yeni analiz veya algoritma karşılaştırması yapılmadı; klinik model yeniden eğitilmedi, hesaplayıcının hesabı değiştirilmedi.